SLP-NLP Lab 2

Επεξεργασία Φωνής και Φυσικής Γλώσσας
Εαρινό Εξάμηνο 2025-26

Μαντζώρος Γεράσιμος, Παπαδημητρίου Νίκη

Απρίλιος 2026

Περιεχόμενα

Μέρος Α΄: Προπαρασκευή

Για τα ζητούμενα της προπαρασκευής χρησιμοποιήσαμε το **Sentence Polarity Dataset (MR)**.

Ζητούμενο 1 – Κωδικοποίηση Επισημειώσεων

Λιστινγ 1: Έ ύμ 1 (main.py:ΕΧ1)

```
% ΤΟΔΟ:
                                10                    λαβελς
```

Ζητούμενο 2 – Λεκτική Ανάλυση (Tokenization)

Λιστινγ 2: Έξοδος Ζητούμενου 2 (δαταλοαδινγ.πψ:ΕΞ2)

```
% ΤΟΔΟ:                                                                10
                  τοκενιζεδ
```

Ζητούμενο 3 – Κωδικοποίηση Παραδειγμάτων (Λέξεων)

Λιστινγ 3: Έξοδος Ζητούμενου 3 (δαταλοαδινγ.πψ:ΕΞ3)

```
% ΤΟΔΟ:                                        5
                                             ΣεντενςεΔαταςετ
```

Ζητούμενο 4 – Embedding Layer

Γιατί αρχικοποιούμε το embedding layer με τα προ-εκπαιδευμένα word embeddings·

Γιατί κρατάμε παγωμένα τα βάρη του embedding layer κατά την εκπαίδευση·

Ζητούμενο 5 – Output Layer(s)

Γιατί βάζουμε μη γραμμική συνάρτηση ενεργοποίησης στο προτελευταίο layer·

Τι διαφορά θα είχε αν είχαμε 2 ή περισσότερους γραμμικούς μετασχηματισμούς στη σειρά·

Ζητούμενο 6 – Forward Pass

Διαισθητική ερμηνεία της αναπαράστασης κέντρο-βάρους:

Πιθανές αδυναμίες της προσέγγισης για αναπαράσταση κειμένων:

Ζητούμενο 7 – DataLoaders

Συνέπειες μικρών και μεγάλων mini-batches στην εκπαίδευση:

Γιατί ανακατεύουμε τη σειρά των mini-batches σε κάθε εποχή·

Ζητούμενο 8 – Βελτιστοποίηση

Κριτήριο (Loss):

Optimizer:

Υπερπαράμετροι:

- Learning rate:
- Batch size:
- Εποχές:
- Άλλες:

Ζητούμενο 9 – Εκπαίδευση

Λιστινγ 4: Σύνοψη εκπαίδευσης

```
% TODO:                                                    (   .
      . loss                        )
```

Ζητούμενο 10 – Αξιολόγηση Baseline Μοντέλου

Πίνακας 1: Αποτελέσματα Baseline μοντέλου

Dataset	Accuracy	F1 (macro)	Recall (macro)
Sentence Polarity (MR)	0.7281	0.7279	0.7281

Σχήμα 1: Καμπύλες εκπαίδευσης (training & test loss) ανά εποχή – Baseline (mean pooling), MR

Ζητούμενο 11 – Κατηγοριοποίηση με Χρήση LLM

Prompts που χρησιμοποιήθηκαν:

Πίνακας 2: Αποτελέσματα ChatGPT

Dataset	**Accuracy**	**F1 (macro)**	**Recall (macro)**
Sentence Polarity	–	–	–
Semeval 2017	–	–	–

Επίδοση μοντέλου:

Ανάλυση αποτελεσμάτων:

Μέρος Β': Κύρια Άσκηση

Για τα ερωτήματα 1–8 χρησιμοποιήσαμε το **Sentence Polarity Dataset (MR)** για τα ερωτήματα 1–5 και και το **Semeval 2017 Task4-A** για τα ερωτήματα 6–7.

Ερώτημα 1 – Mean + Max Pooling

1.1 Υλοποίηση:

1.2 Διαφορές από την αρχική αναπαράσταση: Η διαφορά από την αρχική αναπαράσταση είναι ότι η αρχική χρησιμοποιούσε μόνο τον μέσο όρο των embeddings με mean pooling, ενώ η νέα συνδυάζει, κάνοντας concatenate, τόσο mean όσο και max pooling, καθένα από τα οποία εξάγει χρήσιμη πληροφορία για το sentiment analysis των προτάσεων. Το mean pooling υπολογίζει, για κάθε διάσταση του embedding, τη μέση τιμή της πάνω σε όλες τις λέξεις της πρότασης. Αν σκεφτούμε ότι κάθε διάσταση του εμβεδδινγ αντιστοιχεί σε κάποια αφηρημένη σημασιολογική ιδιότητα, τότε το mean pooling δίνει ένα είδος κέντρου βάρους του νοήματος της πρότασης. Είναι χρήσιμο γιατί περιγράφει ποια χαρακτηριστικά εμφανίζονται συνολικά, αποτυπώνει το γενικό περιεχόμενο, αλλά ταυτόχρονα εξομαλύνει τις πολύ έντονες τοπικές ενδείξεις. Το max pooling, αντίθετα, για κάθε διάσταση κρατά μόνο τη μεγαλύτερη τιμή που εμφανίστηκε σε κάποια λέξη. Έτσι λειτουργεί περισσότερο σαν μηχανισμός ανίχνευσης παρουσίας έντονων σημάτων. Αν μία μόνο λέξη ενεργοποιεί πολύ έντονα κάποια διάσταση, το max pooling θα το διατηρήσει, ακόμη κι αν όλες οι υπόλοιπες λέξεις δεν συμβάλλουν καθόλου εκεί. Αυτό είναι ιδιαίτερα χρήσιμο σε sentiment analysis, όπου μία λέξη με έντονη συναισθηματική φόρτιση, θετική ή αρνητική, μπορεί να μεταφέρει δυσανάλογα μεγάλη πληροφορία για την κλάση. Άρα η συνένωσή τους στη νέα αναπαράσταση εξάγει επιπλέον πληροφορία, γιατί συνδυάζει τη μέση πληροφορία της πρότασης (mean) με την πιο έντονη παρουσία χαρακτηριστικών σε κάθε διάσταση (max).

Πίνακας 3: Αποτελέσματα Ερωτήματος 1 (Mean+Max Pooling)

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**
Mean+Max Pooling	0.7462	0.7454	0.7462

Σχήμα 2: Καμπύλες εκπαίδευσης (training & test loss) ανά εποχή – Mean+Max Pooling, MR

Ερώτημα 2 – LSTM

2.1 Validation set & Early Stopping: Για το validation split χρησιμοποιείται η συνάρτηση torch_train_val_split() στο main.py. Η συνάρτηση αυτή χωρίζει το αρχικό training set σε δύο μέρη: train_loader και val_loader, με default val_size=0.2, άρα χρησιμοποιείται το 20% του training set ως validation set, όπως φαίνεται και στην training.py. Στη συνέχεια εφαρμόζεται early stopping με την κλάση EarlyStopper στο main.py. Σε κάθε εποχή υπολογίζεται το val_loss, και αν αυτό επιδεινώνεται συνεχώς για 5 εποχές, η εκπαίδευση σταματά. Με αυτόν τον τρόπο το μοντέλο δεν εκπαιδεύεται για σταθερό αριθμό εποχών ανεξάρτητα από την απόδοσή του, αλλά σταματά όταν παύει να γενικεύει καλά στο validation set. Αυτό βοηθά στον περιορισμό του overfitting, αλλά και στη μείωση του υπολογιστικού κόστους κατά την εύρεση του βέλτιστου αριθμού εποχών εκπαίδευσης για το δεδομένο dataset.

2.2 Χρήση τελευταίας εξόδου LSTM (h_N): Στο LSTM, κάθε λέξη δεν αναπαρίσταται μόνο από το εμβεδδινγ της, αλλά από μια νέα κρυφή κατάσταση h_i που ενσωματώνει και πληροφορία από τα προηγούμενα tokens. Σε αντίθεση με το απλό RNN, το LSTM διαθέτει μηχανισμό μνήμης μέσω του context/cell state c_t και τριών πυλών: forget, input και output gate. Με αυτές το δίκτυο μαθαίνει ποιες πληροφορίες πρέπει να διατηρήσει, ποιες να απορρίψει και ποιες να χρησιμοποιήσει στην τρέχουσα έξοδο. Έτσι μπορεί να μεταφέρει χρήσιμη πληροφορία σε μεγαλύτερες αποστάσεις και να αντιμετωπίζει καλύτερα το πρόβλημα των vanishing gradients. Για την αναπαράσταση της πρότασης χρησιμοποιείται η τελευταία πραγματική έξοδος h_N, δηλαδή η κρυφή κατάσταση που αντιστοιχεί στο τελευταίο έγκυρο token της πρότασης. Αυτό είναι σημαντικό γιατί τα zero-padded timesteps δεν ανήκουν στο πραγματικό κείμενο και δεν πρέπει να επηρεάζουν την αναπαράσταση. Στην υλοποίηση αυτό εξασφαλίζεται με χρήση των πραγματικών μηκών των προτάσεων και του pack_padded_sequence, ώστε το LSTM να επεξεργάζεται μόνο τα αληθινά tokens, και στη συνέχεια επιλέγεται το output στη θέση lengths - 1.

2.3 Αμφίδρομο LSTM (BiLSTM): Στο αμφίδρομο LSTM η πρόταση διαβάζεται και από τις δύο κατευθύνσεις: από αριστερά προς τα δεξιά και από δεξιά προς τα αριστερά. Έτσι η τελική αναπαράσταση κάθε θέσης περιέχει πληροφορία τόσο από το αριστερό όσο και από το δεξί συμφραζόμενο. Αυτό είναι ιδιαίτερα χρήσιμο στη γλώσσα, επειδή η ερμηνεία μιας λέξης συχνά εξαρτάται όχι μόνο από ό,τι προηγήθηκε αλλά και από ό,τι ακολουθεί. Στην κατηγοριοποίηση προτάσεων, το bidirectional LSTM δίνει συνήθως πιο πλούσια αναπαράσταση του κειμένου από το μονοκατευθυντικό, επειδή συνδυάζει και τα δύο συμφραζόμενα πριν από την τελική ταξινόμηση. Στη δική μας υλοποίηση, με bidirectional=True, το μοντέλο στο dataset MR πέτυχε στο test set τα παρακάτω αποτελέσματα:

Πίνακας 4: Αποτελέσματα Ερωτήματος 2 (LSTM)

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**
LSTM (unidirectional)	0.7568	0.7546	0.7568

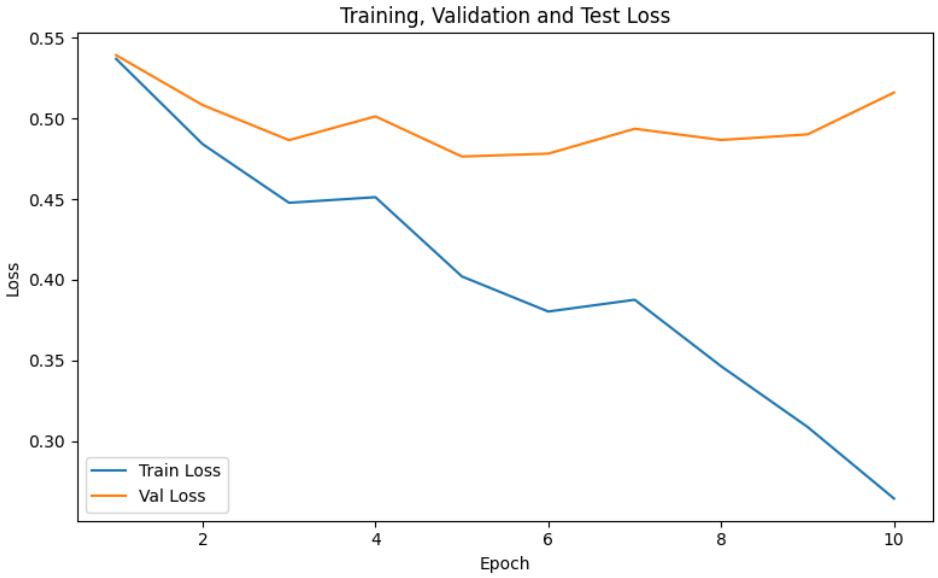

Σχήμα 3: Καμπύλες εκπαίδευσης (training & test loss) ανά εποχή – LSTM, MR

Ερώτημα 3 – Self-Attention

Πίνακας 5: Αποτελέσματα Ερωτήματος 3 (Self-Attention)

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**
Self-Attention	0.7492	0.7489	0.7492

Σχήμα 4: Καμπύλες εκπαίδευσης (training & test loss) ανά εποχή – Self-Attention, MR

3.1 Υλοποίηση & Αποτελέσματα (SimpleSelfAttentionModel):

3.2 Queries, Keys, Values και Position Embeddings:

Ερώτημα 4 – Multi-Head Attention

Πίνακας 6: Αποτελέσματα Ερωτήματος 4 (Multi-Head Attention)

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**
MultiHead-Attention (n_head=4)	0.7477	0.7475	0.7477
MultiHead-Attention (n_head=8)	0.7402	0.7401	0.7402

Σχήμα 5: Καμπύλες εκπαίδευσης (training & test loss) ανά εποχή – Multi-Head Attention, MR

Ερώτημα 5 – Transformer-Encoder

Διαφορά από MultiHeadAttentionModel:

Πίνακας 7: Αποτελέσματα Ερωτήματος 5 (Transformer-Encoder)

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**
Transformer-Encoder (n_head=4, n_layer=3)	0.7492	0.7462	0.7492
Transformer-Encoder (n_head=8, n_layer=6)	0.7477	0.7456	0.7477
Transformer-Encoder (n_head=4, n_layer=6)	0.7704	0.7699	0.7704

Σχήμα 6: Καμπύλες εκπαίδευσης (training & test loss) ανά εποχή – Transformer-Encoder, MR

Default τιμές παραμέτρων στην κλασική αρχιτεκτονική Transformer:

Ερώτημα 6 – Pre-Trained Transformers (Zero-Shot)

Πίνακας 8: Αποτελέσματα Pre-Trained Transformers – Sentence Polarity (MR)

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**
siebert/sentiment-roberta-large-english	0.9260	0.9260	0.9260
textattack/bert-base-uncased-SST-2	0.8988	0.8987	0.8988
distilbert-base-uncased-finetuned-sst-2-english	0.8912	0.8912	0.8912
aychang/roberta-base-imdb	0.8489	0.8485	0.8489
lvwerra/distilbert-imdb	0.8202	0.8195	0.8202

Πίνακας 9: Αποτελέσματα Pre-Trained Transformers – Semeval 2017

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**
cardiffnlp/twitter-roberta-base-sentiment	0.7238	0.7222	0.7229
cardiffnlp/twitter-roberta-base-sentiment-latest	0.7205	0.7226	0.7330
finiteautomata/bertweet-base-sentiment-analysis	0.7178	0.7181	0.7302
cardiffnlp/twitter-xlm-roberta-base-sentiment	0.6926	0.6886	0.6929
Seethal/sentiment_analysis_generic_dataset	0.6184	0.6093	0.6181

Σχολιασμός αποτελεσμάτων:

Ερώτημα 7 – Fine-Tuning Pre-Trained Transformers

Πίνακας 10: Αποτελέσματα Fine-Tuned Transformers – Sentence Polarity

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**

Πίνακας 11: Αποτελέσματα Fine-Tuned Transformers – Semeval 2017

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**

Σχολιασμός αποτελεσμάτων:

Ερώτημα 8 – Διάλογος με ChatGPT για GPT Κώδικα

Παραδείγματα διαλόγου:

Σχολιασμός απόδοσης:

Συγκεντρωτικά Αποτελέσματα

Πίνακας 12: Σύγκριση όλων των μοντέλων – **Sentence Polarity (MR)** (εκτός Pre-Trained Semeval)

Μοντέλο	**Accuracy**	**F1 (macro)**	**Recall (macro)**
Baseline DNN (mean pooling)	0.7281	0.7279	0.7281
Mean + Max Pooling	0.7462	0.7454	0.7462
LSTM	0.7568	0.7546	0.7568
Self-Attention	0.7492	0.7489	0.7492
Multi-Head Attention (n_head=4)	0.7477	0.7475	0.7477
Transformer-Encoder (n_head=4, n_layer=6)	0.7704	0.7699	0.7704
Pre-Trained best (siebert, MR)	0.9260	0.9260	0.9260
Pre-Trained best (cardiffnlp, Semeval)	0.7238	0.7222	0.7229
Fine-Tuned (best)	–	–	–